# **Bioinformática**

## **Trabajo Práctico Final**

#### **Alumnos**

Rivas, Leandro Matias Legajo 51274

> XXXX, Nicolas Legajo 5XXXX

#### **Profesor**

Yankilevich, Patricio

#### Fecha de Entrega

23 de noviembre de 2016

Este trabajo se realizó en lenguaje Perl, utilizando su módulo BioPerl. Se instaló localmente Blast, se descargo la base de datos PROSITE y se utilizó aplicaciones EMBOSS.

El trabajó se realizó sobre la plataforma Ubuntu 14.04 LTS.

Este trabajo práctico final consta de 5 ejercicios, los cuales se detallan a continuación, del 1 al 4, cómo deben ejecutarse.

#### Ejercicio 1.

Se ingresa archivo con formato GenBank y se obtiene 6 archivos con los diferentes orden de lectura en formato Fasta.

```
$ perl e1.pl huntington.gb
```

Luego, ingresando a ncbi.nlm.nih.gov/orffinder se obtuvo el ORF correto: forward 2.

#### Ejercicio 2.a.

Se ingresa archivo Fasta con el orden de lectura correcto y retorna un archivo Blast.

```
Para ejecución de Blast local

$ perl e2alocal.pl f2.fas blastlocal.out
```

```
Para ejecución de Blast remoto

$ perl e2aremote.pl f2.fas blastremote.out
```

### Ejercicio 2.b.

```
Multiple Sequence Alignment (MSA) $ perl e2b.pl ../msa/mas.fas msa.out
```

### Ejercicio 3.

Se ingresa archivo blast, un patrón y archivo de salida.

```
$ perl e3.pl blastremote.out protein match.out
```

## Ejercicio 4.

Se ingresa archivo GenBank y archivo de salida. Este script utiliza las aplicaciones *getorf* y patmatmotifs.

```
$ perl e4.pl huntington.gb hun.modif
```

### Ejercicio 5. Trabajo con bases de datos biológicos.

a) El gen elegido es HTT (Huntingtin). Es un gen relacionado a la enfermedad de Huntington, un trastorno neurodegenerativo caracterizado por la pérdida de neuronas estriadas. Se cree que es causada por una expansión e inestabilidad de la repetición de un trinucleótido en el gen huntingtin, que se traduce como poliglutamina en el producto proteico. Normalmente el trinucleótido se repite entre 9 a 35 veces. Por arriba de 40 veces se describe como una patología.

Se decidió estudiar este gen debido a su influencia con la enfermedad de Huntington. Es hereditaria, con una posibilidad del 50%. Se manifiesta entre los 35 y 50 años. El defecto genético se encuentra a nivel del cromosoma 4.

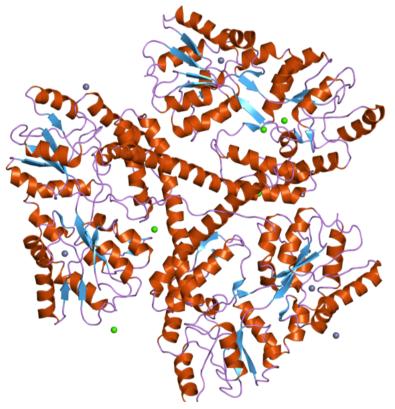


Figura 1. Representación de la estructura molecular de la proteína HTT.

LINK: https://www.ncbi.nlm.nih.gov/gene/3064

b) En la base de datos de **Ensembl** entramos el "Gene Tree" que se muestra en la Figura 2.

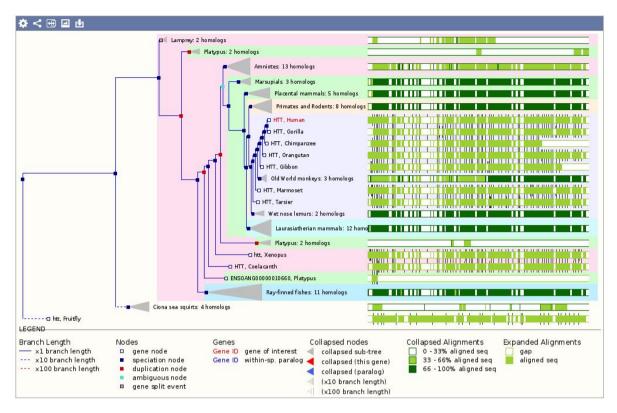


Figura 2. "Gene Tree" obtenida de Ensembl.

En el árbol encontramos los genes homólogos a HTT. Se muestra expandida solo el subárbol que contiene el gen humano (marcado en rojo). Sin embargo, se pueden apreciar la gran cantidad de homólogos que existen.

Se puede observar que en la raíz de del árbol encontramos que se ubica en la categoría taxonómica de los animales, plantas y hongos.

Por otra parte, en la base de datos *HomoloGene* se puede encontrar los genes homólogos presentes en la Figura 3.

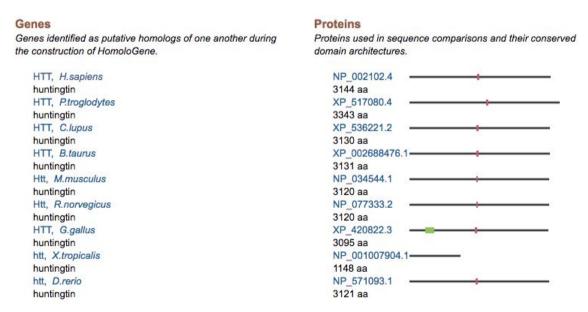


Figura 3. Gene homólogos de HomoloGene.

La información brindada por HomoloGene es mucho más incompleta y compleja de comprender que la que se obtuvo de Ensembl. Solo vemos algunos homólogo de los encontrados en Ensembl, principalmente de la línea de los mamíferos.

c) En Ensembl encontramos 13 formas alternativas de splicing.

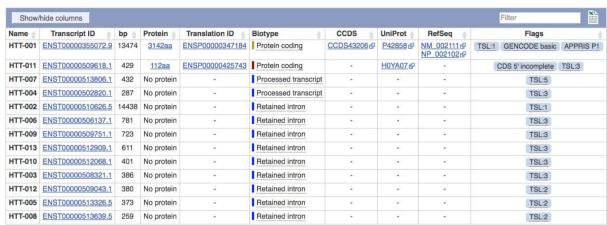


Figura 4. Tabla de transcrips.

Por otra parte, en NCBI encontramos 305 formas alternativas.

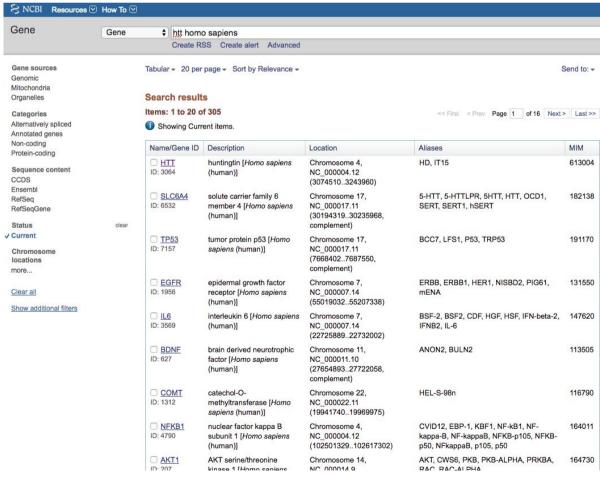


Figura 5. Formas alternativas según NCBI.

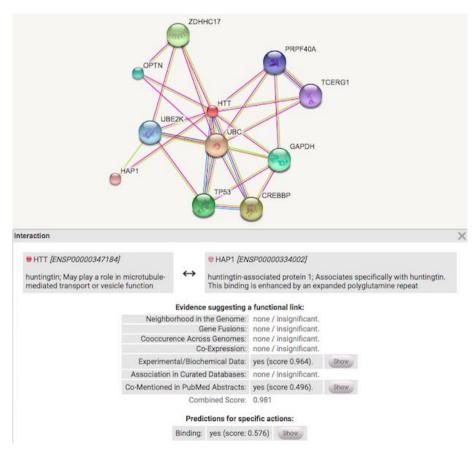
Al buscar razones de esta diferencia entre ambas bases, se encontró que Ensembl, en donde se busco los splicing, realiza las búsquedas solo en base de datos de vertebrados. Es decir, la búsqueda se reduce considerablemente en comparación con NCBI. Ensembl posee páginas complementarias que localizan en otras especies como invertebrados, plantas, bacterias, etc. Por eso, se considera a NCBI como la más precisa de ambas.

d) En el sitio **UniPort** pudimos ver que la cantidad de interacciones proteína-proteína varía de acuerdo a la base de datos que se tome.

Protein-protein int	eraction databases
BioGrid <sup>1</sup>	109314. 220 interactions.
DIP <sup>i</sup>	DIP-32492N.
IntAct <sup>i</sup>	P42858. 354 interactions.
$MINT^1$	MINT-133355.
STRING <sup>1</sup>	9606.ENSP00000347184.

Figura 6. Interacciones proteína-proteína tomada de UniPort.

Al analizar estas bases vimos que rondan las 270 interacciones. La siguiente figura indica los datos obtenidos en **String**, donde cada línea representa una interacción proteína-proteína con HTT.



Flgura 7. Interacción de HTT con otras proteínas.

En NCBI vemos que HTT interactúa con 312 proteínas.

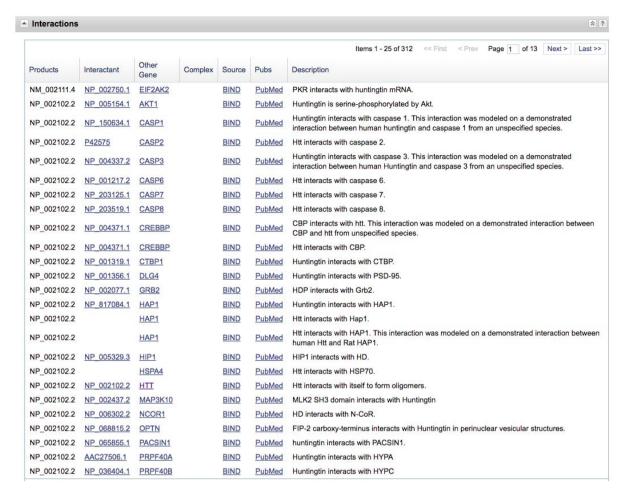


Figura 8. Interacciones obtenidas de NCBI.

e) Para encontrar información sobre las funciones moleculares en las cuales interviene la proteína se encontró en http://www.genecards.org/cgi-bin/carddisp.pl?gene=HTT& keywords=htt. Allí se pudo ver que las principales funciones que realiza son las siguientes:



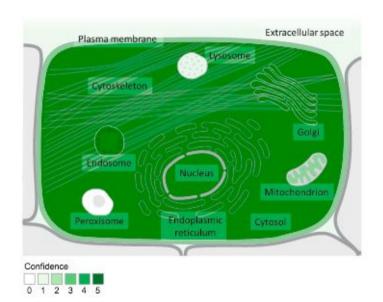
Figura 9. Tabla de funciones moleculares.

- i) **p53 binding**: interactúa selectiva y no covalentemente con uno de la familia de proteínas p53.
- ii) receptor binding: interactúa selectiva y no covalentemente con uno o más sitios

específicos en un receptor molecular, una macromolécula que está sometida a una hormona, neurotransmisor, droga o intracelula mensajera para iniciar un cambio en la función de la célula.

- iii) **protein binding**: interactúa selectiva y no covalentemente con cualquier proteína o proteína compleja (complejidad de 2 o más proteínas que posiblemente no incluyan otras moléculas no proteicas).
- iv) **profilin binding**: interactúa selectiva y no covalentemente con profilina, proteína actin-binding que forma un complejo con G-actin y previene que realice la polimerización para formar F-actin.
- v) **transcription factor binding**: interactúa selectiva y no covalentemente con un factor de transcripción, cualquier proteína requerida para iniciar o regular la transcripción.
- vi) **dynactin binding**: interactúa selectiva y no covalentemente con cualquier parte de un complejo dinactina (*dynactin is a large protein complex that activates dynein-based motor activity*).
- vii) **identical protein binding**: interactúa selectiva y no covalentemente con una proteína idéntica o varias.
- viii) **ion channel binding**: interactúa de forma selectiva y no covalente con uno o más sitios específicos en un canal iónico, un complejo proteico que atraviesa una membrana y forma un canal lleno de agua a través de la bicapa de fosfolípidos permitiendo el transporte selectivo de iones por su gradiente electroquímico.
- ix) **dynein intermediate chain binding**: Interacción selectiva y no covalente con una cadena intermedia del dineína complejo.
- x) **beta-tubulin binding**: Interacción selectiva y no covalente con la proteína constituyente de los microtúbulos beta-tubulin.

También el sitio brinda los componentes moleculares, los cuales se muestran a continuación.



Compartment	Confidence	
cytoskeleton	5	
cytosol	5	
endoplasmic reticulum	5	
endosome	5	
golgi apparatus	5	
nucleus	5	
vacuole	5	
mitochondrion	4	
plasma membrane	4	
extracellular	2	
lysosome	2	

Figura 10. Componentes celulares (COMPARTMENTS).

GO ID 👙	Qualified GO term	Evidence	PubMed IDs
GO:0005634	nucleus	IDA	12783847
GO:0005654	nucleoplasm	IDA	
GO:0005737	cytoplasm	IDA	7748555
GO:0005770	late endosome	IDA	17704510
GO:0005776	autophagosome	IDA	17704510
GO:0005783	endoplasmic reticulum	IDA	17704510
GO:0005794	Golgi apparatus	IDA	15837803
GO:0005814	centriole	IDA	21985783
GO:0005829	cytosol	IDA	20515468
GO:0014069	postsynaptic density	IEA	
GO:0030136	clathrin-coated vesicle	IEA	
GO:0030424	axon	IDA	7748555
GO:0030425	dendrite	IDA	7748555
GO:0030659	cytoplasmic vesicle membrane	IDA	7748555
GO:0043025	neuronal cell body	IEA	
GO:0043234	protein complex	IDA	18922795
GO:0071598	neuronal ribonucleoprotein granule	IEA	

Figura 11. Gene Ontology (GO) - Tabla de componentes celulares del gen HTT.

En cuanto a los procesos biológicos (brindados por Gene Ontology) en los que influye se encontraron los siguientes:

- i) Organización de Golgi
- ii) Desarrollo en sistema nervioso central
- iii) Aprendizaje vocal
- iv) Desarrollo de órganos animales
- v) Transporte de RNA mensajero
- vi) Proceso apoptótico
- vii) Regulación de la actividad de la proteína fosfatasa tipo 2A
- viii) Establecimiento de la orientación del mitótico

f) Para la obtención de los pathways, se ingresó al sitio KEGG. Realizando la busqueda aquí, se obtuvo un solo resulta, el cual se detalla a continuación.

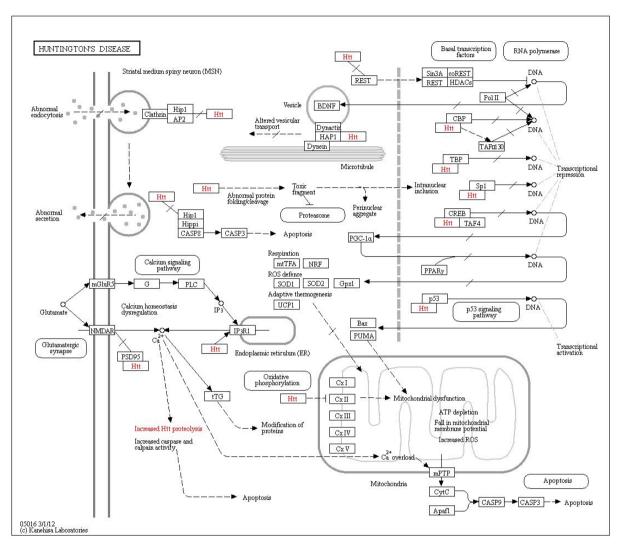


Figura 12. Pathway provista por KEGG.

La enfermedad de Huntington (HD) es un trastorno neurodegenerativo autosómico dominante que afecta principalmente a las neuronas del estriado mediano espinoso (MSN). Los síntomas son choreiformes, movimientos involuntarios, cambios de personalidad y demencia. HD es causada por una expansión repetitiva de CAG en el IT15gene, lo que resulta en un largo tramo de poliglutamina cerca de la amino-terminal de la HD proteína huntingtin (Htt). El Htt mutante (mHtt) tiene efectos tanto en el citoplasma como en el núcleo. En el citoplasma, mHtt de longitud completa puede interferir con el transporte vesicular BDNF en los microtúbulos. Esta proteína mutante también puede conducir a una endocitosis y secreción anormales en las neuronas, debido a que la Htt normal forma un complejo con las proteínas Hip1, clatrina y AP2 que están implicadas en la endocitosis. Además, el mHtt afecta a la señalización de Ca2+ sensibilizando InsP3R1 a la activación por InsP3, estimulando la actividad de NMDAR y desestabilizando el manejo de Ca2+

mitocondrial. El mHtt cambia su ubicación al núcleo, donde forma inclusiones intranucleares. Se cree que la toxicidad nuclear es causada por la interferencia con la transcripción génica, lo que conduce a la pérdida de la transcripción de moléculas neuroprotectoras tales como BDNF. Mientras que mHtt se une a p53 y aumenta los niveles de p53 nuclear, así como la actividad p53 transcripcional. La p53 aumentada media la disfunción mitocondrial.

g) Para este inciso se buscaron variantes genéticas que produce la enfermedad de Huntington en la base de datos de SNP por medio de NCBI, entre la que encontramos la variante llamada rs82334 ( https://www.ncbi.nlm.nih.gov/projects/SNP/snp\_ref.cgi?rs=82334). La consecuencia de esta variación de acuerdo a NCBI es el "intron\_variant", que el sitio sequenceontology lo define como una variante de la transcripción que ocurre dentro de un intrón.

#### rs82334 [Homo sapiens]

CCCGCTGAAGCGTCCAGCAGCTTCA[A/C]CCAGGCCGTTTTCCTTCATTGCTAG

Chromosome: 4:3223644
Gene: HTT (GeneView)
Functional Consequence: intron variant

Validated: by 1000G,by 2hit 2allele,by cluster,by frequency

Global MAF: C=0.2841/1423

HGVS: NC\_000004.11:g.3225371A>C, NC\_000004.12:g.3223644A>C,

NG\_009378.1:g.153970A>C, NM\_002111.6:c.7631+84A>C, NM\_002111.7:c.7631+84A>C,

XM\_005247964.1:c.7577+84A>C, XM\_005247965.1:c.6911+84A>C

PubMed

Figura 13. descripcion de rs82334 de ncbi.nlm.nih.gov/snp.

No se pudo encontrar en la fuente información relacionada a la frecuencia o grupo étnico al que afecta.

#### **Enlaces**

Lista de enlaces consultados para la realización de este trabajo.

- https://www.ncbi.nlm.nih.gov/gene/3064
- <a href="http://www.informatics.jax.org/marker/MGI:96067">http://www.informatics.jax.org/marker/MGI:96067</a>
- http://www.ensembl.org/Homo\_sapiens/Gene/Compara\_Tree?collapse=36218844%
   2C36218829%2C36219027%2C36218890%2C36219062%2C36218885%2C362190
   60%2C36218942%2C36219001%2C36218933%2C36219036%2C36218959;db=core;g=ENSG00000197386;r=4:3074681-3243959
- <a href="http://www.kegg.jp/kegg-bin/search\_pathway\_text?map=map&keyword=htt&mode=1">http://www.kegg.jp/kegg-bin/search\_pathway\_text?map=map&keyword=htt&mode=1</a> &viewImage=true
- <a href="http://www.ensembl.org/Homo\_sapiens/Gene/Compara\_Tree?db=core;g=ENSG000">http://www.ensembl.org/Homo\_sapiens/Gene/Compara\_Tree?db=core;g=ENSG000</a> 00197386;r=4:3074681-3243959
- <a href="https://www.ncbi.nlm.nih.gov/homologene?LinkName=gene\_homologene&from\_uid=3064">https://www.ncbi.nlm.nih.gov/homologene?LinkName=gene\_homologene&from\_uid=3064</a>